**Relatório 1 - Vídeo: O Que é Aprendizado de Máquina (I)**

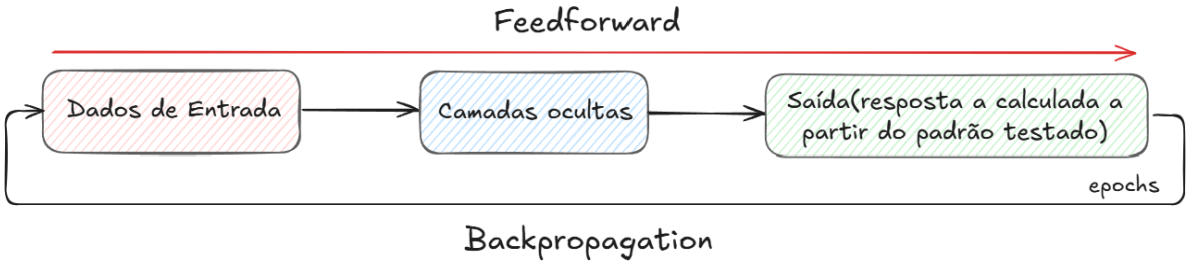
Eduardo Andrei Staudt

# 1. Introdução

O objetivo desta aula foi ter um primeiro contato e aprender o básico sobre as redes neurais e *ML*(*Machine Learning*). A tarefa consistia em assistir a dois vídeos e abstrair uma visão introdutória de redes neurais (estrutura, treino, tipos) e de como o computador aprende padrões a partir de dados em vez de regras.

# 2. Desenvolvimento

Imagem 1 - Estrutura de Redes Neurais.




Fonte: autoria própria feita com o Excalidraw.

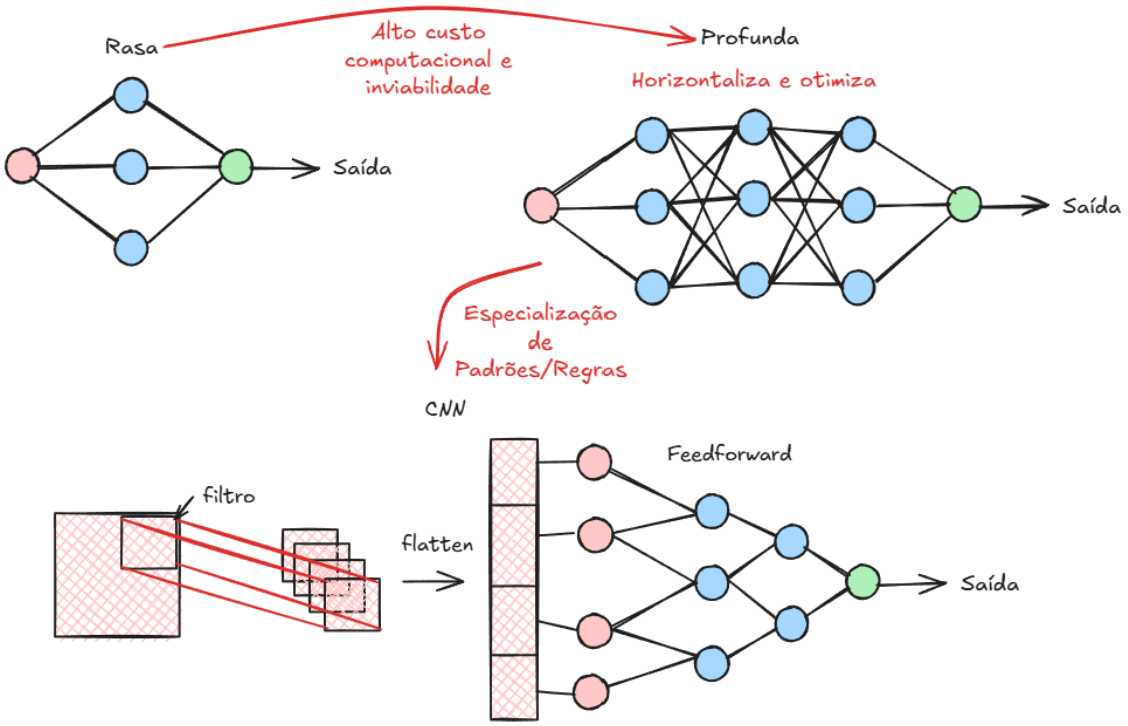
A imagem 1 busca mostrar a estrutura básica de uma rede neural identificada através dos vídeos, primeiramente entendi que uma rede neural consiste numa estrutura:

- **Camada de Entrada(*Input Layer*):** ela consiste em um dataset com dados de entrada. Estes dados têm respostas que depois são utilizados para calcular a *loss*.
- **Camada Oculta(*Hidden Layer*):** ela pode ser composta por N camadas densas e uma camada densa é composta por N neurônios artificiais com seus *bias*(constante somada ao neurônio para balancear a rede) cada um com peso e níveis de ativação diferentes.
- **Camada de Saída(*Output Layer*):** aqui é onde a rede neural devolve o resultado aproximado da entrada que ela calculou através dos padrões por ela identificados e utilizados.

Mas a rede neural melhora através de auto-ajustes feitos pelo *optimizer(*ajusta os pesos*)* com o backpropagation(cálculo dos gradientes no sentido contrário da rede) durante as *epochs*(quantidade de vezes que a rede vai ser

treinada/reajustada) que busca diminuir a função de perda(*loss function)* que é o parâmetro que mede o erro da rede.

Imagem 2 - Tipos e estruturas de redes neurais.




Fonte: autoria própria feita com o Excalidraw.

Um conceito importante obtido através dos vídeos foi o do Teorema da Aproximação Universal que diz que todo problema que pode ser respondido através de uma função contínua pode ter um resultado aproximado por uma rede neural rasa, que consiste numa estrutura de rede com uma única camada densa. O que esse teorema não diz é a quantidade de neurônios mais o bias necessários para fazer a aproximação.

Geralmente quanto mais dados de treinamento a rede possuir melhores os resultados que ela retornará. Levando isso em conta com conjunto de dados de treinamento muito extenso(como na quantidade de pessoas no grupo do vídeo) tem-se um gargalo computacional em que o tempo e custo ficam inviáveis nas redes rasas pois a camada densa necessita de muitos neurônios, para resolver isso existem as redes neurais profundas que utilizam da mesma lógica mas em vez de utilizar uma única camada verticalizada com muitos neurônios, a quebramos em mais camadas densas tornando-a mais escalável.

Existem casos em que seria interessante poder tornar a rede neural mais especializada com uma capacidade melhor de abstrair os padrões mais específicos, para isso existe a rede neural convolucional que funciona como a que está na Imagem 2, primeiro é aplicado um filtro deslizante em vários pedaços da entrada o que realça os padrões mais importantes, depois disso é feito o flatten que faz a

vetorização permitindo assim que a rede feedforward seja treinada para reconhecer esses padrões evidenciados, permitindo assim a rede se especializar melhor para determinado padrão. Isso é importante por exemplo quando vai se trabalhar com imagens pois às vezes as imagens podem ter muitos ruídos como o background de imagens que pode chamar muita atenção e assim enviesar a resposta da rede ou no exemplo do vídeo o pedra papel tesoura onde para fazer a tesoura pessoas usam três ou dois dedos levantados, isso pode ser um ruído, utilizando as convoluções é possível realçar outros padrões que a identifiquem mesmo em ocorrências como esta.

# 3. Conclusão

Os vídeos me mostraram o ML e os diferentes tipos de redes neurais como a rasa que pode encontrar uma aproximação da função contínua, mas não é escalável, a profunda que resolve isso, mas não é tão boa em especializar e a convolucional que resolve essa parte quando necessária. O mais importante é que elas são ferramentas que buscam otimizar a maneira como o computador aprende padrões a partir de dados, com elas o computador faz isso usando as entradas com resultados já conhecidos para assim desenvolver a capacidade de aproximação dos padrões, o que caminha no lado contrário da programação tradicional.