Relatório 5 - Prática: Estatística p/ Aprendizado de Máquina (I)

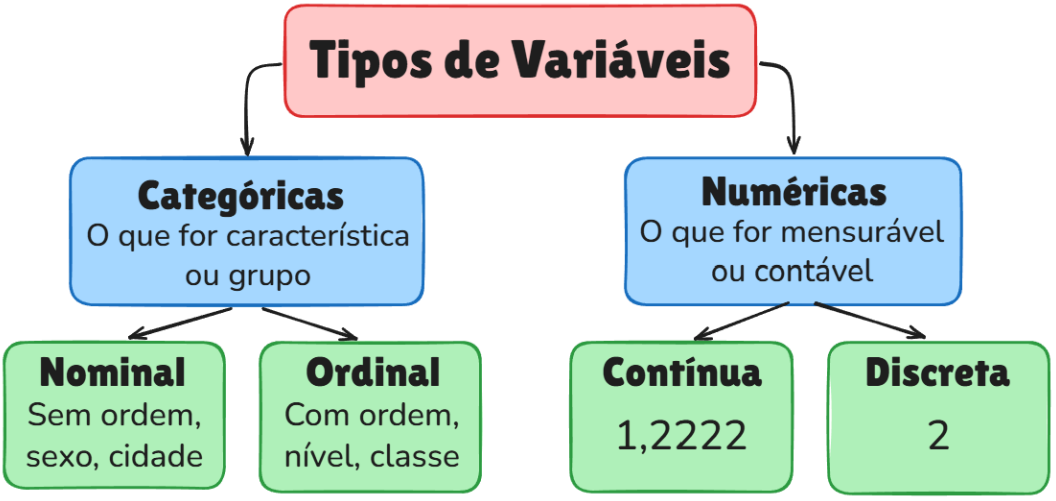
Eduardo Andrei Staudt

1. Introdução

O objetivo deste card foi através do Curso 1, ensinar sobre estatística, esse aprendizado é essencial para programadores que têm de trabalhar com dados, pois é ele quem permite fazer análises críticas buscando informações e interpretações úteis. No decorrer do curso aprendi sobre as classificações numéricas, média, moda, mediana, variância, funções de probabilidade, tipos de distribuição, percentiles, momentos, geração de gráficos, covariância, correlação, probabilidade condicional e o Teorema de Bayes.

2. Desenvolvimento

Imagem 1 - Resumo visual sobre tipos de variáveis.



Fonte: autoria própria feita com o Excalidraw.

Inicialmente aprendi sobre os tipos de variáveis representadas na Imagem 1 que são a categórica (representa características podendo ser de forma ordinal ou nominal) e numérica (representa quantidades discretas ou contínuas).

A segunda aula consistiu em aprender média, moda e mediana, que representam respectivamente:

- **Média**: a soma dividida pela quantidade de valores.
- **Moda**: o número que mais aparece entre os analisados.

- **Mediana**: é o valor central. Se a quantidade for par, é a média dos dois centrais.

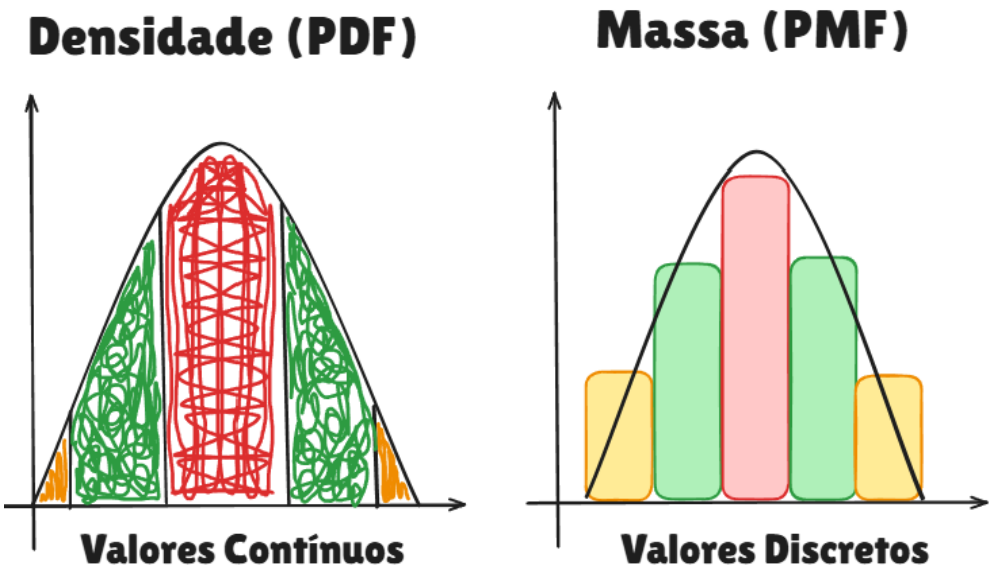
As métricas acima são extremamente importantes e sendo a base de diversas outras métricas e no python podem ser aplicadas usando *Numpy* e *Scipy*.

Na terceira aula aprendi sobre variância e desvio padrão que calculados respectivamente:

- **Variância Populacional**: mede a dispersão de todos os valores de uma população em relação à média populacional, calculando a soma dos quadrados dos desvios e dividindo por N.
- **Variância Amostral**: mede a dispersão dos dados de uma amostra em relação à sua média, calculando a soma dos quadrados dos desvios e dividindo por n - 1.
- **Desvio Padrão Populacional**: mede a dispersão de todos os valores de uma população em relação à média populacional. Só calcular a raiz quadrada da variância populacional.
- **Desvio Padrão Amostral**: mede a dispersão dos valores de uma amostra em relação à média amostral. Só calcular a raiz quadrada da variância amostral.

Ambas as métricas são fáceis de serem usadas pois estão no *Numpy*.

Imagem 2 - Funções de probabilidade.



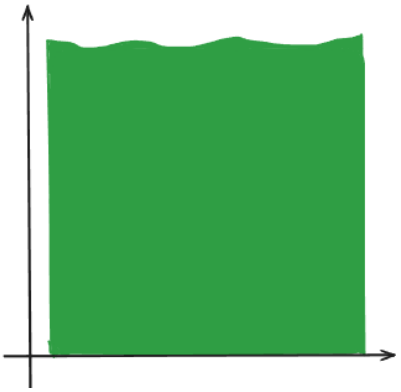
Fonte: autoria própria feita com o Excalidraw.

Na quarta aula aprendi sobre os dois tipos de função de probabilidade: a de massa que é para valores discretos e a de densidade que é para valores contínuos, representei o gráfico das mesmas na Imagem 2.

Na quinta aula aprendi os principais tipos de distribuição, que são:

Uniforme: nela há uma chance igual de qualquer valor ou intervalo de valores ocorrer, tem no *Numpy*.

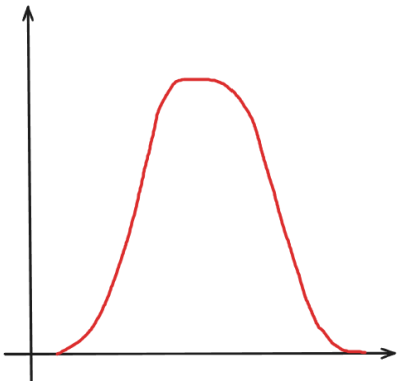
Imagem 3 - Gráfico de distribuição uniforme.



Fonte: autoria própria feita com o Excalidraw.

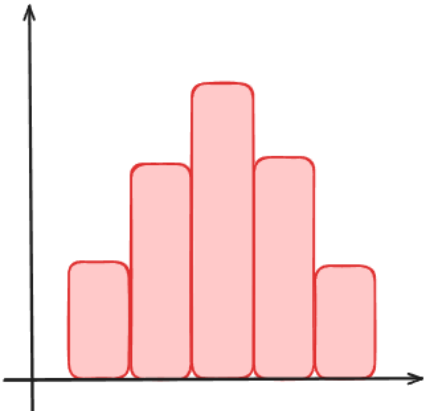
Normal/Gaussiana: distribuição contínua representada por uma curva em formato de sino ela tem a maioria dos seus dados centrados na média para usá-la é necessária a utilização do *Numpy* e do Scipy(`norm.pdf`).

Imagem 4 - Curva de distribuição normal.



Fonte: autoria própria feita com o Excalidraw.

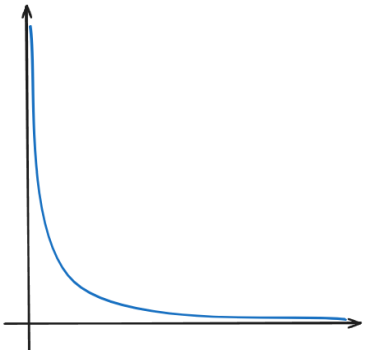
Imagem 5 - Histograma de distribuição normal.



Fonte: autoria própria feita com o Excalidraw.

Exponencial PDF / Power Law: curva decrescente muito utilizada para representações ao longo do tempo, precisa de *Numpy* e *Scipy*(`expon.pdf`).

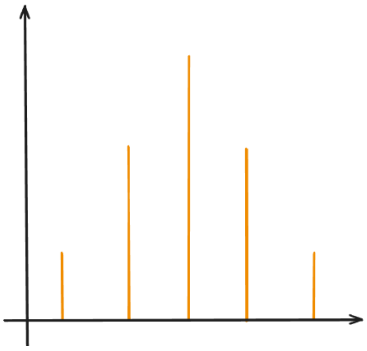
Imagem 6 - Gráfico de distribuição exponencial decrescente.



Fonte: autoria própria feita com o Excalidraw.

Binomial: para valores discretos, ela calcula a probabilidade de obter certa quantidade de sucessos em um número fixo de tentativas, para usar precisa de *Numpy* e *Scipy*(`binom.pmf`).

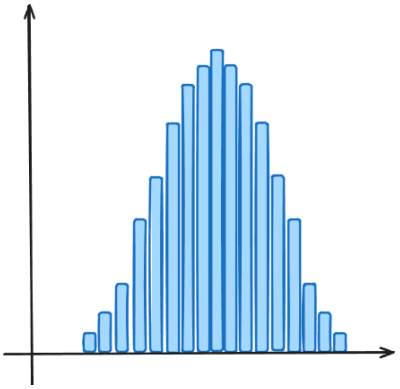
Imagem 7 - Gráfico de distribuição binomial.



Fonte: autoria própria feita com o Excalidraw.

Poisson: distribuição discreta que calcula a probabilidade de uma quantidade de eventos ocorrer em um intervalo, com eventos independentes e taxa média constante, para usar precisa de *Numpy* e de Scipy(`poisson.pmf`).

Imagem 8 - Gráfico de distribuição de Poisson.



Fonte: autoria própria feita com o Excalidraw.

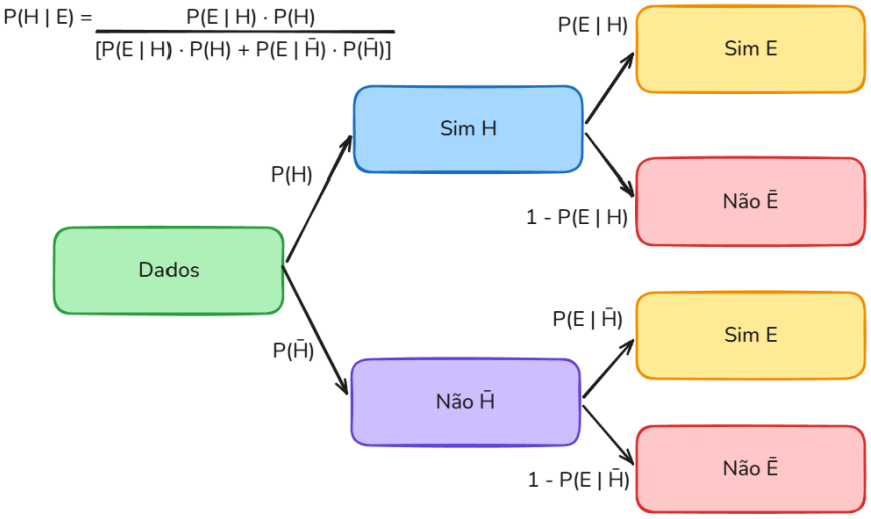
Na sexta aula aprendi sobre percentis e momentos que são respectivamente: são medidas de posição que dividem um conjunto de dados ordenados em 100 partes com aproximadamente a mesma quantidade de observações, são medidas estatísticas calculadas a partir de potências dos valores de uma variável ou de seus desvios em relação à média o que é bom pra identificar características dos dados. As duas podem ser utilizadas através das *libs Numpy* (`percentile, var, mean, median`) e *Scipy* (`kurtosis, skew`).

Na sétima aula aprendi a mexer melhor no *Matplotlib* vi como sobrepor gráficos, alterar cores/estilos, colocar legendas, ajustar limites, marcações e adicionar grade. Aprendi novos tipos de gráficos como o de dispersão e o *boxplot*. Na oitava aula aprendi sobre o *Seaborn* que é um *Matplotlib* mais profissional nele dá para fazer gráficos com mais configurações e gráficos mais complexos como heatmap, *boxplot* de dispersão, dispersão mais histograma com *scatter*, e outros isso permite obter resultados melhores pois permite aprofundar buscas e visualizar de mais de uma forma.

Na nona aula aprendi sobre covariância e correlação que mostram a relação entre duas variáveis e como elas variam em conjunto. A covariância indica se elas tendem a aumentar ou diminuir juntas, ou se seguem sentidos opostos. Quando ela é positiva, valores maiores de uma variável tendem a acompanhar valores maiores da outra. Quando é negativa, valores maiores de uma tendem a acompanhar valores menores da outra. A correlação padroniza essa relação em uma escala de −1 a 1, o que permite comparar variáveis com unidades diferentes. Na prática, ela ajuda a descobrir quais têm mais relação com a variável alvo e quais são redundantes entre si, dá pra usar na seleção de features antes de treinar um modelo. Uma correlação próxima de zero indica apenas ausência de relação linear, então modelos como redes neurais ainda podem capturar relações não lineares que ela não detecta.

Nas aulas 10 e 11 aprendi sobre probabilidade condicional que é a chance de um evento ocorrer sabendo que outro evento já ocorreu. Essa informação restringe os resultados possíveis aos casos em que o evento conhecido aconteceu. Por exemplo, ao lançar um dado e saber que o resultado foi par, a chance de ter saído seis é uma em três, pois os únicos resultados possíveis são dois, quatro e seis.

Imagem 9 - Representação da árvore de probabilidades do Teorema de Bayes.



Fonte: autoria própria feita com o Excalidraw.

E por fim na décima segunda aula do curso aprendi sobre o Teorema de Bayes que usa uma estrutura de árvore de probabilidades essa que representei na Imagem 9. O teorema consiste em atualizar a chance de uma hipótese ser verdadeira quando aparece uma nova informação. Na árvore, primeiro separamos os casos em que a hipótese é verdadeira ou falsa. Depois, mostramos se a evidência aparece ou não em cada caso. Para calcular a chance de cada caminho, multiplicamos as probabilidades dos seus ramos. A fórmula pega o caminho em que a hipótese é verdadeira e a evidência aparece e divide pelo total dos caminhos em que essa evidência aparece. Assim, descobrimos a chance de a hipótese ser verdadeira sabendo que a evidência aconteceu.

3. Conclusão

O curso me ensinou a estatística primordial para que eu consiga interpretar e gerar métricas, manipular dados e extrair características dos dados que tenho em mãos. Além disso, também me ensinou a trabalhar com o *Matplotlib* e *Seaborn* que permitem visualizar dados através de gráficos, o que ajuda muito a entender o que acontece e como estão dispostos os dados. Com esses conhecimentos adquiridos agora já consigo ter uma base estatística para poder trabalhar com a parte de análise de dados que é necessária durante praticamente todas as etapas do aprendizado de máquina.

4. Referências

KANE, Frank; SUNDOG EDUCATION TEAM. ***Machine Learning, Data Science & AI Engineering with Python***. Udemy, 2026. Curso on-line. Disponível em: <https://www.udemy.com/course/data-science-and-machine-learning-with-python-hands-on/>. Acesso em: 31 ago. 2026.