Relatório 6 - Vídeo: O Que É Ciência De Dados (I)

Eduardo Andrei Staudt

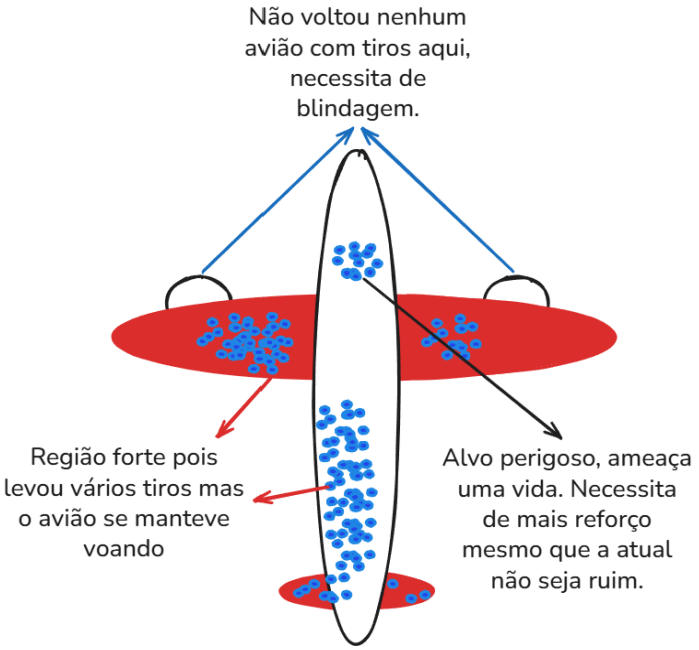
1. Introdução

O objetivo deste card foi entender o que é a Ciência de Dados. Para isso, assisti a dois vídeos, nos quais compreendi como ela pode ter diferentes significados, abrangendo diversas áreas. Entendi também como ela se aplica ao aprendizado de máquina, fundamentando a qualidade dos resultados.

2. Desenvolvimento

Inicialmente, assisti ao Vídeo 1 (Nerdologia), que me explicou como saber analisar dados e extrair lições pode ser muito útil. Para isso, usamos a ciência de dados. Um exemplo é o de Abraham Wald, que trabalhava com otimização de blindagem. Para melhorar a blindagem de aviões, ele decidiu coletar informações de furos de bala dos cascos dos aviões. Foi através desses dados que ele obteve diversas informações que o ajudaram em decisões, como pontos críticos, onde blindar e locais que naturalmente aceitam mais impacto, entre outras análises. Retratei essa ideia na Imagem 1, abaixo:

Imagem 1 - Exemplo de análise de Abraham Wald.

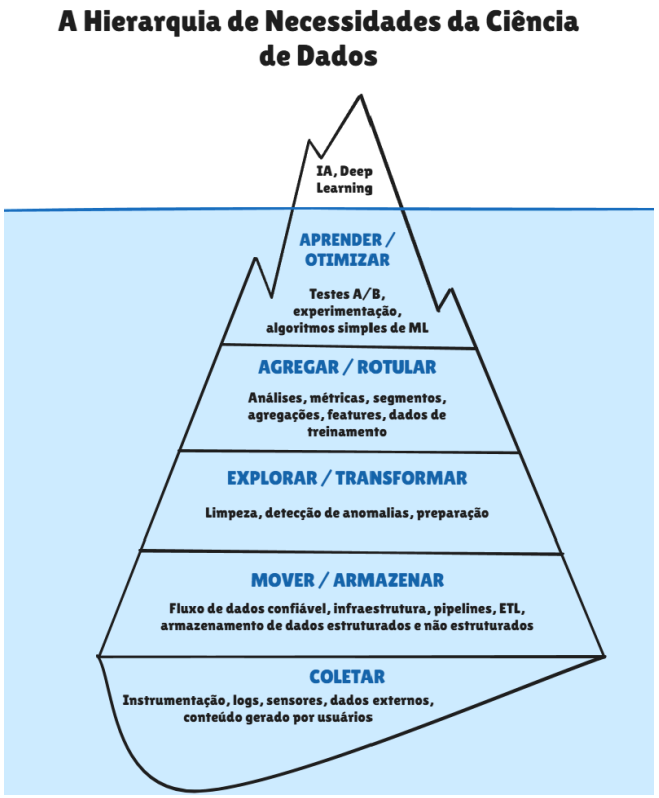


Fonte: autoria própria feita com o Excalidraw.

Depois dessa introdução, entendi a diferença entre Estatística, que é entender o que os dados mostram, e ciência de dados, que são os padrões não explícitos que existem nesses dados. Entendi também que é justamente isso que acontece no ML (*Machine Learning*), a rede é treinada para conseguir encontrar esses padrões e, assim, prever uma variável. Nesse cenário de ML, o cientista de dados entra mais como um garantidor de qualidade de dados do que como um localizador de padrões, pois quem faz isso é a própria rede. Com isso, o papel dele é garantir que os dados sejam bons para que, assim, a rede gere resultados bons também.

No Vídeo 2 (Joma Tech) , entendi o que realmente é a ciência de dados na parte corporativa. O valor dela não aparece em gráficos bonitos nem em codar, e sim em gerar o máximo possível de impacto através dos dados que a empresa possui. Esse impacto pode vir de várias formas, como *insights*, *data products*, *product recommendation*, entre outros. A ciência de dados está na junção da estatística com a computação. Atualmente temos uma grotesca quantidade de dados dos mais diferentes tipos. Por causa disso, surgiu o *Big Data*, que trata de volumes e variedades de dados grandes demais para as ferramentas tradicionais, exigindo tecnologia e infraestrutura próprias, como os grandes *Data Centers*. Nesses dados é aplicada a ciência de dados, que aparece no ML e na IA, mas esse não é o foco. O verdadeiro foco está em como isso resolve os problemas das empresas.

Imagem 2 - Hierarquia de necessidades do *Data Science*.



Fonte: Adaptado de Joma Tech (2018), feito no Excalidraw.

No vídeo é usada uma figura semelhante a essa (só traduzi e fiz uma analogia com um iceberg) para explicar as necessidades da ciência de dados, que funcionam numa hierarquia, a seguinte:

1. **Coletar (base)**: instrumentação, *logs*, sensores, dados externos, conteúdo gerado por usuários, isso geralmente as empresas têm de monte.
2. **Mover/Armazenar**: fluxo de dados confiável, infraestrutura, *pipelines*, ETL, armazenamento de dados estruturados e não estruturados.
3. **Explorar/Transformar**: limpeza, detecção de anomalias e preparação, importante para garantir dados verdadeiramente bons e válidos.
4. **Agregar/Rotular**: análises, métricas, segmentos, agregações, *features*, dados de treinamento, importante para saber o nível de sucesso.
5. **Aprender/Otimizar**: testes A/B, experimentação, algoritmos simples de ML, interessante para verificar os melhores produtos.
6. **IA, *Deep Learning* (topo)**: uma possível aplicação de tudo isso que vem anteriormente, mas, como mostrado na Imagem 2, é só a ponta do iceberg.

Com isso, o Vídeo 2 se encerra deixando conceitos extremamente importantes, diferenciando o pensamento comum do corporativo sobre o que é ciência de dados, pensamento esse que pode variar bastante de acordo com o nível e os recursos de cada empresa.

3. Conclusão

Os vídeos me fizeram entender que a ciência de dados é saber usar os dados para ver mais do que eles mostram e gerar o maior impacto possível. Essa abstração me fez entender a relação com a principal pergunta que as redes neurais fazem: “Quais padrões eu posso extrair desses dados?”. Para que elas retornem bons resultados, antes preciso entender como coletar, manipular, explorar, agregar e otimizar os dados. Esses conceitos são extremamente importantes para a construção de um *Mindset* voltado ao aprendizado de máquina.

4. Referências

JOMA TECH. **What REALLY is Data Science? Told by a Data Scientist.** YouTube, 23 jun. 2018. Disponível em: https://www.youtube.com/watch?v=xC-c7E5PK0Y. Acesso em: 29 out. 2026.

NERDOLOGIA. **O que é ciência de dados | Nerdologia Tech**. YouTube, 26 jul. 2018. Disponível em: https://www.youtube.com/watch?v=ykSILAQQu6o. Acesso em: 29 out. 2026.